FilingRevisionQA：补充材料

本文档为论文的独立补充材料，不包含于公开资源核心包。仓库入口为https://github.com/ZiBo-Zhang-web/FilingRevisionQA，公开核心包上传完整性正在核验。 核心包采用限于自有内容的MIT和CC BY 4.0许可，维护人为ZiBo Zhang。主文以S编号引用本文档；会议是否接受单独上传该PDF仍未确认，软件资源字段不视为增加论文页数的许可。

本材料将成对资源评价连接到构建记录、控制实验与复现流程。核对资源构建与人工审核沿革可从S11读起；S1 – S4提供适配、控制与外部任务结果，S5 – S7说明解释边界、包验证与评分修订，S8 – S10提供成对结果图示和保留输出的分项分析。 S12汇总相关资源的任务与评价对象，S13保留完整实验设置、计数及限定，S14保留精简主文对应的完整方法与解释记录。

S1 来源绑定与固定适配

S1.1 来源绑定改变总体与成对结果

来源绑定提高总体开发正确数，同时降低十个变化开发状态中的正确数（表S1）。规则解析期间、单位和范围；只读问题的LLM解析器采用相同排序过程，输出无效时回退规则。

表S1。 来源绑定提高总体正确数，同时降低变化状态正确数。

Qwen开发条件	J/144	P/72	变化J/10
软回退恢复	78	35	4
规则解析与排序	95	40	4
LLM解析与排序	94	39	4
规则解析、排序与来源绑定	102	48	2
LLM解析、排序与来源绑定	102	48	2
相同五事实及顺序，补原文上下文	101	49	4
上下文数字遮蔽（诊断）	103	47	5

表注：各条件使用相同Qwen阅读模型和预算上限；绑定基于公共相关性及受理时间同分规则。证据长度不同。末行为事后遮蔽归因控制，十个变化状态来自五个发行人。

LLM解析器在不绑定时使联合正确数变化-1，绑定时变化零，校正p均为1.0；49/72个机械检查通过的提案表示解析接受数。绑定将变化状态正确数由4/10降至2/10。该资源因而可以区分总体回答合规性的收益与小规模变化子集的收益。

隔离参考的审计进一步定位绑定带来的转换。122/144个状态完成事实映射，所有映射事实满足截止时间，108个通过过滤，前五证据中的目标事实出现数由87升至93。十个改善中，七个只修复引用一致性而不改变数值或accession，两个修复accession，一个加入目标事实。三个退步的输入都已经包含正确事实，其余22个状态的映射状态未知。

给相同五条事实补充上下文产生六个改善和七个退步。七个退步均等于参考值除以1000，尽管单位名称与accession正确。数值遮蔽部分减少了缩放错误，同时也删除日期并缩短输入。因此，上下文对照暴露了缩放敏感的失败现象，其归因边界保留在第6.1节。

S1.2 适配提高可支持训练接口上的开发表现

固定适配提高了可支持训练接口上的总体分数。公开规则绑定输入先冻结，再把既有训练参考映射到引用。582个训练状态中281个满足接口：245个优化状态、36个loss留出状态，分别来自47/8个发行人。四个预先指定近模板样例及297个缺少类型或精确支持的状态保持排除，不据此构造弃答标签。

每项LoRA运行[25]使用一轮结束的最终模型，rank为16、alpha为32、dropout为0.05、学习率为0.0001。种子43/44用相同数据和配置重复seed42；评价保留全部144个开发状态及精确的未适配输入。

表S2。 固定适配种子的总体成绩高于各自未适配对照。

资源适配条件	J/144：42/43/44	P/72：42/43/44	变化J/10：42/43/44
Qwen	111 / 112 / 112	54 / 55 / 55	5 / 6 / 5
Phi	106 / 108 / 106	49 / 53 / 51	5 / 5 / 5

表注：J使用144状态，P使用72问题对，变化状态分母为十。报告全部固定种子，统计样本单位见第5.1节。

未适配Qwen和Phi分别为102/144、90/144。适配后三种子联合正确率均值与样本标准差分别为77.55% ± 0.40个百分点、74.07% ± 0.80个百分点。

变化状态正确数为Qwen 5/6/5、Phi 5/5/5，分母均为十。seed42增益为6.25/11.11个百分点，Holm校正符号翻转p均为0.127。首卡直接复制控制得到101/144联合正确、49/72双状态正确、5/10变化正确，包含14项无效输出。这一控制使“复制行为”成为解释适配阅读模型的明确比较对象。

精确来源支持可在83/144个输入上判定，其余61个未知。Qwen附带指定引用的联合正确数随种子为77/67/76，尽管总体分数相近。后续上下文训练得到Qwen 115/115/116、Phi 109/109/110；相同公告、指标和单位、不同期间的干扰训练得到115/114/116、108/111/110，保持245/36划分和单轮配置。平均差为-0.23/+0.23个百分点，Holm p均为1.0，变化正确数保持6/10和5/10。这些单独登记的条件提供了期间干预的阴性结果。

S2 覆盖与编号控制

内部留出评价显示了可支持接口收益的转移范围。已检查的留出集有86状态，来自14个训练分区发行人，均排除在优化之外：36个可支持loss留出、42个缺精确绑定、八个原文回退。seed42适配将Qwen由39变为41/86，将Phi由36变为41/86；二者各子层计数均为34/36、6/42、1/8。Qwen弃答由26降至零，合法但联合错误由12升至31。两个USD/share状态保留分母，在原生单位复评后仍未计为联合正确。

引用编号也会影响结果。在其余字节和tokenizer长度不变时循环替换ID，Qwen基础/适配联合正确数保持102/111；Phi由90/106变为71/110，基础模型新增21项accession与引用冲突。无效输出不计入等变性成功数。该控制评价固定编号置换，与内容访问对照相互补充。

S3 输出格式控制

协议合法性和联合正确性对输出约束呈现不同响应。实验交叉未适配权重、保留的seed42适配器，与自由贪心、JSON外壳语法、外壳加数值字符串约束三种解码。语法允许null；参考值和目标accession留在线下。每个家族的六个条件均在同一运行环境重新生成，提示词、证据顺序和预算不变。

表S3。 数值输出约束新增的联合成功来自答案未变化状态。

模型与权重	自由J	外壳J	数值约束J	P：自由→约束	变化J：自由→约束
Qwen未适配	103	103	103	49→49	2→2
Qwen适配	111	111	113	54→54	5→5
Phi未适配	88	90	94	41→44	4→4
Phi适配	109	109	110	52→53	6→6

表注：J使用144状态，P使用72问题对，变化J使用十状态。全部对照在同一环境新生成，与表S2的历史运行环境分开；软件与成本见补充材料S5.4。

四项预定“数值约束减自由输出”比较的发行人聚类Holm p均为1.00，区间均包含零。Qwen适配新增14条合法输出，由130升至144，联合正确增加二；Phi适配新增四条合法输出，由140升至144，联合正确增加

一。四项比较新增的九个联合成功均来自未变化状态。在相同数值约束下，适配相对未适配的差距仍为10/144、16/144。

这些结果把输出兼容性与成对事实目标分开：所测试的约束更容易弥补合法性缺口，而不是联合答案缺口。该设计下，等价性及格式因素的因果贡献比例仍未确定。两种约束解码均增加时延。

S4 外部FinQA

S4.1 固定检索与生成流程复现

外部FinQA研究[1]使用三个完整检索器和生成器种子，相同科学代码、上游revision、解码配置及1,147个测试ID。每个种子内FQ2与FQ3检索替换条件共享选定生成器，FQ2/FQ3为内部条件名。检索器产生的证据及选定权重随种子变化，因此这里复现完整流程。

表S4。 FQ2在各种子的执行与程序正确数上高于FQ3。

种子	FQ2执行	FQ2程序	FQ3执行	FQ3程序
42	699	670	516	499
43	697	667	512	489
44	724	696	530	510
平均准确率（%）	61.61	59.08	45.28	43.53
样本标准差（百分点）	1.31	1.39	0.82	0.92

表注：各计数分母1,147；全部6,882条条件预测通过原官方评分器复评。多种子复用相同问题，而非形成3,441个独立观测。

FQ3平均执行正确率下降16.33个百分点，在这一冻结替换下FQ2保留更高结果。seed43经授权的封装接续保留了一条缺结束符的开发程序、错误结果和完整883条分母；训练、token、beam和checkpoint选择均未改变。关联接续与seed44原流程各完成17阶段，原失败保留在备份沿革中。

S4.2 Coder适配

独立Qwen2.5-Coder研究[26]使用官方FinQA训练样例，固定3,183条优化、487条内部留出、一轮训练和883条开发输入。同输入未适配执行正确109/883，初始LoRA种子42/43/44得到533/533/504，均值59.27%、样本标准差1.90个百分点，程序正确473/466/460。FinQANet的572/883是不同架构参考。

单独登记的词法、随机、神经检索干扰变体分别得到562/557/550、576/559/546、570/562/569，后者均值567/883，各配置保留自己的种子汇总。单个最佳种子不是稳定架构比较。这些实验给出外部数值程序接口表现，SEC成对任务及其gate独立保留，预训练污染仍未排除。

S5 审计与回顾性分析

S5.1 文献阅读覆盖

比较针对已实现任务接口与测量目标，不横比不同任务的成绩。Same-Number Citation Swaps提供主文第2节讨论的引用角色对照[20]。定向文献核验保留不可访问材料及检索范围记录，不宣称穷尽覆盖。

AhaSignals时点资源包含八个真实SEC案例、16个提示，其500标量对研究包含17个差异和483个未变化对照。回顾性文档核验覆盖17个差异及三个对照。13个差异可与精度差异相容，四个超出舍入区间，17个的原因均未确定。相关比较使用已检查的作者资源说明，关联SSRN正文不可访问。Bai和Chen的比较依据已发布资源及补充材料，而非未取得的主论文。这些材料为真实SEC版本、未变化金融对照和来源可追溯性提供先例；表S13描述已实现任务，不假定既有资源无法扩展。

S5.2 人工与来源记录

作者已确认机械投影公共题干完成人工审核。该确认作为批次声明保存，并连接精确的投影ID集合及题干哈希；本次确认未提供逐项审核人身份、审核日期或逐题意见文件，相应字段保持未填写。技术审计另行核对转换、两态输入及参考和来源映射，不新增人工判断。

机器辅助构建和修复在人工审核前均为暂定、不可进入评价。所有保留ID来自初始盘点，AI筛选路径记录处理决策，而非人工估计错误率或统一人工排除分类。裁决者看到两份返回，因此属于知情裁决而非第三份独立盲审。作者确认描述审核行为，审核过程本身未经直接观察；空白人工标签保持空白。

原始审核一致率比较字段字符串，而非语义一致性或正确性。未决类别排除在已决类别结论之外，全部事件不统一标为确认重述。公共审核记录去除身份和私人通信。结构检查及精确来源重建验证保留环境下的解析和定位，语义解释是单独审核问题。

S5.3 单位配置、失败与辅助分析

主表使用resource-native-v1。历史自主比较保持不变；原生完整来源结果属于保留输出敏感性估计，历史校正比较另行登记。

历史配置支持USD和shares，因此四个pure测试状态不能计为联合正确。统一复评覆盖173个条件/队列组的25,930条规范QA输出，包括全部保留普通测试轮次。数值、参考、解析结果和生成文本均不改变；非QA选择/似然记录及未映射合成记录在本次审计之外。只有Qwen完整来源的两个状态改变联合分数，历史配置与推断统计仍可辨认。

无效输出保留主要分母，首失败顺序区分引用冲突与后续accession不匹配。accession不匹配既不表示公告事实必然为假，也不表示修订普遍取代所有未变化原文。辅助可读数字计数不替换主要分数。语义解释和错误归因保持暂定，未知来源映射不自动判错。案例在已观察结果类别内按ID哈希确定性选取，用于说明保留结果而非估计发生频率。数值遮蔽同时删除日期并缩短输入，来源容器在组成和覆盖上不同，因此各控制按真实干预解释。

S5.4 实验历史、修复与计算成本

登记表保留最初单事实普通测试及840输出、表示搜索、全部适配家族及失败。旧机器参考实验与人工审核队列分别处理。紧凑五条证据的补充比较保持Qwen 90/210，将Phi由81/210变为76/210，校正p均为1.0；这些历史记录保留，不汇为独立重复。

跨模型解析器类型修复复用31条输出，输入与接受规则不变。一条生成未落盘形成审计缺口，后续生成先写journal再解析，全部1,770逻辑记录保留。一项上下文实验改变了14条未变化回退的键序；对账复用精确原始输出，得到101/144，没有新生成。两版本分别归档，工程对账和单位复评不增加模型重复次数。

适配使用Qwen RTX PRO 6000和Phi RTX 4090，预留显存峰值分别37.76至42.31、13.32至15.48 GiB。格式因子实验使用两台RTX 4090，环境为PyTorch 2.9.0+cu128、Transformers 4.51.3、PEFT 0.15.2、lm-format-enforcer 0.11.3，保留1,728次真实调用、零缓存及105,705生成tokens。生成循环时间合计4,194.92秒，另有加载、哈希和归档时间。固定执行顺序及负载限制时延比较，成本台账区分阶段墙钟时间、模型循环、缺失测量和租用时间。

S5.5 复用与发布状态

离线复用及固定lxml/libxml2/libxslt的来源重建保留失败记录及成功跨平台结果，确认已测试的离线路径；实时SEC来源可访问性是独立检查。审核题干沿革与评价输入保留。主文3.5列出仓库、限于自有内容的许可和维护联系信息。作者及单位采用作者提供的元数据；基金信息尚未提供。第三方许可继续适用，历史复现包与公开核心包保持区分。

S6 历史包验证

资源预览支持组件替换和来源级答案检查。Python 3.10+加载器验证成员与哈希，公共加载提供问题、截止时间、时钟协议和指令，实验执行器加入系统指令及检索证据。离线参考和审核沿革分别存储。

资源卡、示例和许可清单覆盖336份公告、938个来源URL/哈希，以及1,555条包含context和单位的XML记录。检索使用70份开发公告、84份测试公告。项目SEC客户端访问官方URL并核对预期哈希，固定解析资产

支持精确历史提取。独立包解压到代码库外，在不使用第三方包或网络的条件下通过42项测试和八条命令，覆盖936条参考、468条题干沿革、938文件来源计划，以及144条保留输出的精确复评，结果为J102/P48。

新组件工具封存新请求；重建历史提示使用保留的历史资产，两者是不同入口。API分离不等于保密保证，片段蕴含与语义充分性需要各自检查。主文3.5列出核心包入口、限于自有内容的许可和维护人；历史包的排除项继续保留于本文档。

发布核心包v1.0.0（文档修订r3）保留同一数据和评分代码，配有加载器、字段说明、资源卡、官方来源下载计划及无证据合成接口示例。干净解压后，在无网络、无GPU条件下通过67项测试和七条命令。核心包不包含历史来源片段/预测复评包、基础权重或环境；上文历史复评成绩属于原复现包。仓库入口为 https://github.com/ZiBo-Zhang-web/FilingRevisionQA，公开核心包上传完整性正在核验。 核心包已记录限于自有内容的许可及维护人；实时SEC来源恢复与仓库下载核验是不同检查。

S7 保留输出诊断修复与题干分层

S7.1 版本化修复

修订包明确区分成对可比较性。旧便携评分器可能将两个协议合法、但单位无法识别的输出误记为错误变化，原因是把无法建立相等关系当作不相等。新诊断要求两个单位均可识别，否则该对标为不可判定。数值、单位、accession及主要联合评分仍使用不变的resource-native-v1配置，历史代码与原始输出保留。

冻结清单包含164个保留文件，即原152文件清单和十二个已验收格式控制条件。27,658条规范状态/条件记录的统一核对精确复现了25,930条历史状态评分及12,965条历史成对诊断。相对旧便携实现，128组中的239条重复问题对/条件记录由错误变化改为不可判定；它们不是239个独立问题。旧稿主表与既有错误变化计数均不变，因为原稿审计已经采用可比较性保护。合成及非问答标识单独记录，不推断映射到规范队列。此次统一保留输出审计不生成新回答，也不用于选择模型。

S7.2 题干分层描述

表S5按已有题干沿革和参考答案变化拆分证据恢复输出。它描述同一个已暴露普通测试集，题干类别还伴随问题及发行人构成差异；不能据此确认语义等价或隔离题干措辞的因果影响。

表S5。 题干沿革区分保留证据恢复结果的构成。

题干	参考变化	状态/问题对/发行人	Qwen J/P	Phi J/P
截止适用性投影	未变化	40/20/6	10/4	10/4
截止适用性投影	变化	2/1/1	0/0	0/0
前缀投影	未变化	64/32/9	39/17	33/10
前缀投影	变化	6/3/3	2/0	2/0
逐字保留	未变化	84/42/14	36/15	35/14
逐字保留	变化	14/7/6	3/1	1/0

表注：J使用该行状态分母，P使用该行问题对分母。发行人可跨层重复，不能相加。机器可读分析保留全条件发行人bootstrap区间和分层计数。单一发行人或全零经验重采样可产生退化区间，该区间不能独立估计总体精度。分层用于检查题干沿革，已完成人审的确认记录见S5.2；不用于追溯删题或重新选择方案。

S7.3 结构覆盖概况

表S6只报告已保留的显式字段。公告受理年份不同于报告年份，定位模态描述记录结构而非证据充分性。

表S6。 显式元数据描述来源年份、单位及定位覆盖。

字段	取值	数量	统计单位
公告受理年份	2019	1	公告
公告受理年份	2020	7	公告
公告受理年份	2021	109	公告
公告受理年份	2022	65	公告
公告受理年份	2023	58	公告
公告受理年份	2024	64	公告
公告受理年份	2025	32	公告
参考单位	iso4217:CAD	8	状态
参考单位	iso4217:USD	848	状态
参考单位	iso4217:USD per xbrli:shares	6	状态
参考单位	xbrli:pure	8	状态
参考单位	xbrli:shares	66	状态
定位模态	html	76	状态
定位模态	html+xml	860	状态

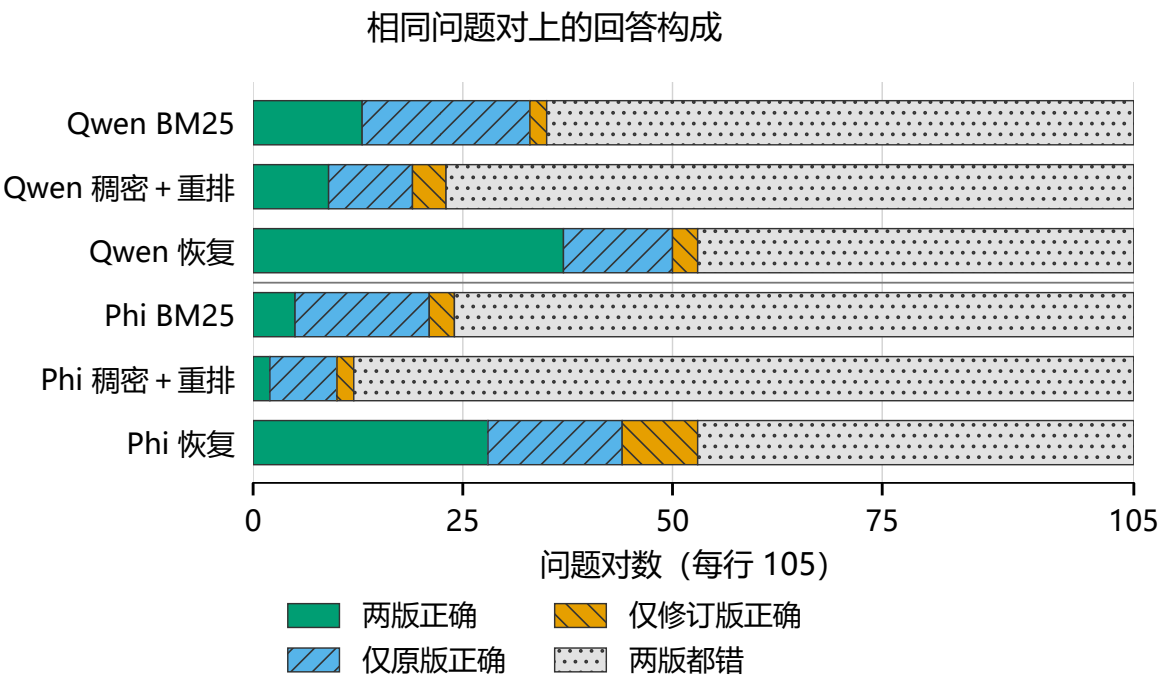
表注：本审计使用的公共公告元数据没有form字段，因此未从文件名推断form计数；语义问题类型分类亦未报告。这里说明的是元数据覆盖边界，不表示这些类别数量为零。原资源、参考及划分成员均未改变。

S7.4 复现入口

修订候选保留历史评分器，并新增paired_diagnostics_v2.py。QUICKSTART_NEW_COMPONENT.md说明公共加载、证据验证、消息封存、阅读输出和离线评分；build_component_requests.py构建新组件接口且不读取参考答案。历史实验输入单独保留。修订随附审计冻结、逐状态和逐对结果、排除记录、差异台账及脚本，复算使用保留输出而不调用模型。

S8 成对结果的图形比较

图S1将表S14转为图形，计数保持不变。每条横柱保留全部105个问题对，两态成功、单侧成功与共同失败之和使用同一分母。



图S1。六个自主条件的成对结果呈现方向不对称。每个条件均为同一普通测试集的105问题对，重复条件不是新增独立问题。

S9 保留已解析字段的数值匹配

保留字段诊断将可读答案匹配与完整响应协议分开呈现。它比较已保存parsed JSON中的answer字符串及规范单位，不依赖记录中的协议状态；原始输出、Markdown和自然语言正文均不重新解析或修复。表S7采用resource-native-v1，并保留全部计划状态。

表S7。 保留答案字段显示主要协议门控之外的数值匹配。

阅读模型与条件	可读数值匹配/210	可读数值及单位匹配/210
Qwen • 截止时间过滤BM25	64	60
Qwen • 稠密检索及重排	42	39
Qwen • 证据恢复	95	91
Qwen • 正确公告BM25（R）	60	56
Qwen • 完整来源容器（R）	158	156
Phi • 截止时间过滤BM25	49	44
Phi • 稠密检索及重排	30	27
Phi • 证据恢复	93	92
Phi • 正确公告BM25（R）	51	46
Phi • 完整来源容器（R）	119	117

表注：每行保留全部210状态，R与主文表4的参考辅助条件相同。单位匹配采用原生配置，不可用的已解析字段不计匹配。辅助计数不改变主要分数，评价的是字段一致性，证据是否支持答案仍是另一项评价目标。历史与原生诊断分别保留；Qwen完整来源条件的单位配置差异见第5.1节和S5.3。

S10 证据构成与回顾性分析

以下分项分析说明队列沿革、收益异质性、候选池与各评分阶段的结果。

S10.1 版本沿革与时钟构造

历史400对审核core与当前468对属于不同选择。按保留的source-question ID对应，两者交集208，旧core独有192，当前队列独有260。因此，当前集合不是旧core的简单扩展。表1追踪的是890→485→468构建路径，修订证据提供逐ID对应表；早期阶段没有的变化标签不从最终划分倒填。

936状态的截止时间均等于指定公告的Accepted时间，每对原版截止时间均更早。公共时钟协议为SEC_acceptance_proxy_not_verified_publication。该构造、发行人路由及稀疏适用公告池提供较强任务约束；来源匹配衡量既定任务的符合性，而非无限定修订发现能力。

S10.2 回顾性收益异质性

使用种子20261029，对29个发行人簇进行20,000次有放回抽样，每次保留两方法、每题两状态及两模型共同进入，全部计划失败保留。增益定义为恢复减BM25，交互差为变化层增益减未变化层增益。变化层含十个发行人的22状态/11问题对，未变化层含29发行人的188状态/94问题对；全部抽样均包含两层。

表S8。 恢复增益差描述变化与未变化状态的不同表现。

阅读模型	变化层增益，pp [95%区间]	未变化层增益，pp [95%区间]	两层差，pp [95%区间]
Qwen	-9.09 [-35.72, 14.29]	23.40 [9.20, 37.50]	-32.50 [-61.06, -2.24]
Phi	0.00 [-14.29, 13.64]	27.66 [18.27, 37.50]	-27.66 [-45.95, -9.22]

表注：区间为type-7逐项百分位95%区间，不是家族校正后的确认性结果。这是已暴露普通测试上的回顾性分析，没有因果差中差识别或新p值。两个阅读模型的变化层自身增益区间均包含零；两层差区间描述该样本的异质性，未检验模型间交互差异。

Qwen在变化状态改对/改错1/3，在未变化状态为61/17；Phi分别为1/1、61/9。因此，正向净收益来自未变化状态，与个别变化状态被改对同时成立。计算冻结附有全部抽样、发行人充分统计量、逐状态结果及输入哈希。

S10.3 实验候选集合

表S9。 实际候选池区分文档、事实与自然段落。

测量项	开发	普通测试
计划状态	144	210
语料公告	70	84
事实索引记录	85,125	68,348
事实路由公告：中位数[范围]	2 [1, 3]	2 [0, 3]
事实候选：中位数[范围]	1,802 [332, 6,963]	1,363 [0, 8,110]
段落候选：中位数[范围]	2,082.5 [539, 7,564]	1,820 [0, 5,316]
空段落池	0	10

表注：这些是保留实验语料，不是全部SEC公告或完整资源来源登记。事实路由由冻结公共辅助函数重建，段落数量连接到原BM25/重排top20记录，顺序精确一致。空状态保留计划失败，不新增“不可回答”标签。原路由没有纳入未来来源；少量公告及指定截止契约限制文档发现泛化。

S10.4 完整来源错误构成

表S10。 完整来源错误在协议与数值层呈现不同分布。

模型/划分	状态	协议/前置失败	合法但N错	N对U错	NU对A错	J
Qwen开发	144	23	54	0	0	67
Qwen测试	210	22	30	2	0	156
Phi开发	144	48	60	1	0	35
Phi测试	210	56	38	2	0	114

表注：按保留的resource-native-v1评分顺序互斥计数，包含全部计划状态。这是参考辅助的原文容器条件，划分组成与上下文预算不同，不能据此对成绩差异作因果归因。

S10.5 协议与前置失败的保留状态

表S11。 七类保留状态区分协议与前置失败。

保留状态	记录数
弃答	209
数值输出不合法	140
引用与accession不一致	132
未提供证据	60
JSON不合法	55
达到输出长度上限	15
结构不合法	12
合计	623

表注：六个自主条件重复使用同一组210测试状态，形成1,260条条件×状态记录。互斥的保留状态标识流程中的首个结果。132条引用与accession不一致已包含在623条失败中；表S16后续的10条指定来源错误已通过协议、数值和单位检查。此处只提取既有评分，不是对所有潜在语义缺陷的分类。

S11 构建与审核记录

S11.1 资源记录层

表S12。 关联记录将成对问题连接到来源。

记录层	数量	用途
问题对	468	同一问题的两个公告状态
状态	936	状态特定的答案和来源目标
发行人	144	隔离划分成员
公告	336	已识别来源文档
来源URL/哈希记录	938	精确来源恢复计划
XML记录	1,555	context、单位与来源沿革

表注：数量对应保留资源快照中的记录层。来源URL/哈希与XML记录是不同统计单位；划分和变化对数量见表2。

S11.2 审核、题干与修正

独立审核之前完成了67项有原文依据的题干修正。人工返回接受464对，另4对经修正后接受；相对于送审队列，数值答案、单位和裁决后题干保持不变。期间注释及4题涉及的10项定位修正分别留有记录。构建决策、人工判断和技术修复的区分见补充材料S5.2。

独立返回和裁决记录共同描述审核过程。裁决人阅读两份返回后作出判断。作者确认审核员A逐题阅读两版原文，提供审核员B完成日期，并确认人工裁决；原始声明与后续确认分别保留。

两份独立返回在468个问题对、144个事件的问题文本、ID及两版accession上完全一致。受控字段一致数为：问题结论449/468、期间类型466/468、事件结论144/144、事件类别130/144。19项问题结论分歧属于“证据不足”与“接受”的差异。原始答案单元格一致数为原版397/468、修订版396/468。这里比较未经归一化的字符串，数值缩放和格式会影响一致率。本文报告原始一致性计数；未计算校正偶然一致性的 κ 系数。

公共题干中240条保留已审核原文，另228条采用固定机械投影：167条替换公告介绍性前缀，61条明确截止时间适用性。作者已确认这些投影题干完成人工审核。原始与公共题干、转换类别及此次确认均可追溯，全部已报告预测保留原评价输入。技术核对检查了保留文本、两态问法及参考映射。11个变化测试问题中4个经过投影；审核依据见补充材料S5.2。

11个事件、45个问题对保留未决类别。它们参与数值问答；已决类别分析使用其余133个事件、423个问题对。公共字段不包含审核人身份和私人通信。

S11.3 来源检查

来源哈希和定位符使数据转换可以逐项检查。Arelle检查覆盖266个XML文件、1,555个定位符和860条状态记录，其余76条状态使用HTML证据。

修正记录保留旧值、新值、理由、来源证据、审核沿革及受影响产物。已接受人工判断、暂定机器分析、未决类别和技术修复使用不同记录类型，使使用者既能恢复已评价版本，也能检查后续修正。

S12 相关资源任务比较

表S13。 相关资源的任务与评价对象。

资源或研究	比较对象	已记录的评价或分析
FinRank [11]	问题及支持、干扰段落	检索、重排序和困难负例辨别
AhaSignals时点基准 [7]	不同决策时点的财务量	时点回答与控制性accession
AhaSignals标量研究与原文核查 [8, 9]	历史标量对	数值差异及选定样本的上下文、精度核查
VersionQA / FiscalQA Pro [13, 12]	版本化技术文档、税法文档	版本相关回答与时间定位
AuditFraudBench [10]	原版、重述公告及执法材料	归因、叙事和欺诈模式任务
FilingRevisionQA	原公告与修订公告上的同一问题	数值、单位、指定来源及成对结果

表注。 各行依据所列文献的任务描述；完整阅读范围和访问限制见S5.1。该表不枚举每项资源的全部能力。

S13 完整评价记录

以下保留父稿中的设置、计数与限定。主文第5节呈现聚焦的比较，表号使用新映射，历史评分配置及实验身份保持不变。

S13.1 评价协议与成对指标

评价协议要求系统在原版与修订版公告的截止时间下分别回答同一问题。每份回答先对照相应状态的参考进行评分，再将两份结果配对，评价系统能否在两种状态下都回答正确。

逐状态评分先检查协议合法性V，再评价回答。V包括引用与所提供证据的accession一致性；引用冲突在这一层被拒绝，随后才评价状态指定accession。设N为与参考的有限十进制数值精确相等，U为规范单位相等，A为与状态指定accession相等。主要数值、数值加单位、联合正确分别在全部计划状态上平均V × N、V × N × U、J = V × N × U × A。因此，数值指标要求回答先满足协议条件，分母仍为全部计划状态。

无效输出在主要指标中计零分，即使其中存在可读数字。格式或数值无效、引用冲突、弃答、缺证据和长度失败分别统计。辅助数值诊断只读取保留的已解析JSON字段，不提取Markdown或自然语言中的数字，也不改变主要评分。accession相等衡量指定来源要求；事实真伪、引用蕴含和修订覆盖范围分别需要证据。

主要resource-native-v1配置支持USD、shares、CAD、USD/share和pure。统一保留输出复评将它与历史USD/shares配置对照。所有自主主结果保持不变；Qwen完整来源条件由154/210变为156/210，双状态由74/105变为75/105。完整评分覆盖和复评过程见补充材料S5.3。

成对评分记录正确回答如何分布在两个公告状态上。双状态指标在问题对上平均P = J(原版) × J(修订版)，并报告两版都正确、仅原版正确、仅修订版正确及两版都错这四类互斥结果。参考数值与单位定义变化、未变化子集。

在未变化问题对中，错误变化要求两端预测均合法、单位均被固定单位配置识别，且预测数值或单位不同。该计数同时使用全部未变化问题对和可判定子集作为分母报告。在变化问题对中，旧答案沿用要求修订状态预测合法且单位可识别，其数值与单位等于原版参考、同时不同于修订参考。无效回答、未知单位、缺失输出和弃答保留各自状态。这些规则将回答稳定与缺答区分，也将原版参考沿用与任意重复错误数值区分。

S13.2 受控证据访问与定位指标

参考辅助条件提供不同程度的定位信息。正确公告BM25接收参考accession，自行选择公告内证据；完整来源容器使用参考定位，提供完整表格或段落及其标题、上下文。构建器保留行列结构，不复制答案字段。这些条件衡量增加证据访问后的表现，与自主回答分开报告。五条证据预算覆盖134/144个开发状态及200/210个测试状态，两个划分各余十个状态保留为失败。跨模型诊断另从106份哈希核验HTML独立重建438个来源容器，在证据预算内覆盖354个开发/测试状态中的334个。

检索指标评价系统能否定位记录中的支持锚点。参考定位定义指定来源与已知目标定位任务，没有池化相关性判定或经判断的负例段落。本文在明确候选池上报告已知目标Hit@k与倒数排名，未标注的支持不进入这些目标计数。同源别名也可在accession、数值、单位、期间及URL/哈希/XPath一致时命中。这些指标评价已知目标的事实与来源匹配；语义相关性与证据充分性需要额外判断。

S13.3 实验范围与阅读模型设置

开发与普通测试实验语料分别包含70/84份公告。按公开发行人、截止时间及结构化事实的题干显式表单路由后，每状态可见公告中位数均为2，范围分别为1–3、0–3；自然段基线候选中位数为2,082.5、1,820，结构化事实使用另一种表示。测试有10个空路由状态，全部保留分母。补充材料表S9分别给出这一少量公告环境中的事实与段落候选规模。

固定Qwen2.5-7B-Instruct与Phi-3.5-mini-instruct共享证据和语义指令[23, 24]。各自使用原生聊天模板、BF16贪心解码、batch size为一、最多五条证据、8,192总token预算及512生成token预留。每项运行附有模型revision和精确输入哈希。

实验登记区分普通测试分析、开发消融、参考辅助诊断和外部FinQA研究。跨模型轮次的2,478条逻辑记录包括2,291次新调用、137次精确消息缓存和50次前置失败，另复用1,062条已接受Qwen记录。合计3,540条模型、条件、状态记录复用相同问题队列。缓存限于相同模型与协议，每个模型、条件、状态均保留计划结果。历史搜索、修复和计算成本详见补充材料S5.4。

S13.4 统计分析

发行人层面的配对分析保留问题和公告状态之间的相关性。跨模型协议固定10,000次发行人bootstrap、100,000次配对发行人符号翻转，随机种子为20261026。六项预定比较使用Holm校正：Phi恢复分别对两种检索基线，以及各阅读模型的正确公告对BM25、完整来源对正确公告。

种子标准差以百分点表示训练波动，跨条件和种子的问题样本保持固定。期间干扰比较先逐状态计算候选与对照在相同训练种子下的结果差，再对这些差值跨种子取平均，随后按发行人重采样并使用Holm2。

此前单事实、解析、表示和seed42适配家族分别保留自己的校正。内部留出与引用编号区间使用10,000次发行人bootstrap、种子20261027；统一单位审计使用相同次数和种子计算回顾性边际区间。

保留输出支持按题干转换类型开展回顾性分层分析，保留全部既有转换类型及变化/未变化组。发行人bootstrap区间描述观测组；单一发行人及边界退化重采样不能独立估计总体不确定性。该分析不选择新测试的模型、提示词或样本子集。

回顾性增益异质性分析使用20,000次共同发行人重采样，随机种子20261029，保留两种方法、两种状态及两模型共同抽样，报告全部预定分量与逐项百分位区间。计算方案在既有结果方向已知后固定（补充材料S10.2）。

分层与成对评价分别呈现回答组成、两版结果和答案变化状态的表现。证据访问对照、开发适配、原文案例及输出约束随后在各自的实验条件下进一步考察这些结果。

S13.5 分层指标区分回答结果

自主比较中，恢复方案提高了两个阅读模型的状态级联合正确率和双状态正确率。表4依次呈现每个条件的协议合法、数值与单位匹配、指定来源及双状态正确数。本节使用已暴露普通测试上的单一冻结协议，其中Qwen比较复用既有输出。

表注：V、VN、VNU和J均保留全部210个计划状态，P保留全部105个问题对。VN和VNU分别表示通过协议门控的数值、数值加单位匹配；V包含引用与accession一致性检查。R表示参考辅助访问。输入、规则及resource-native-v1固定，历史配置差异见第5.1节。

恢复方案在Qwen和Phi上分别得到37/105、28/105个双状态正确问题对。按状态级联合正确率计算，Phi相对BM25增加24.76个百分点，配对发行人聚类95%区间为[16.51, 33.66]、Holm p = 0.000080；相对稠密检索增加31.90个百分点，区间为[22.82, 41.36]、p = 0.000060。接下来按题对区分这些提升来自哪些结果。

S13.6 成对评价定位收益来源

恢复方案的正向净增益来自答案未变化状态。表S14和表S15定位具体结果变化，而不把总体分数直接作为修订响应能力的度量。

表S14。 成对结果揭示单侧成功和共同失败。

自主条件	两版皆对	仅原版对	仅修订版对	两版皆错
Qwen BM25	13	20	2	70
Qwen 稠密重排	9	10	4	82
Qwen 恢复	37	13	3	52
Phi BM25	5	16	3	81
Phi 稠密重排	2	8	2	93
Phi 恢复	28	16	9	52

表注：每行将全部105问题对分为互斥结果；历史和原生评分配置的自主条件计数相同。

表S15。 恢复方案的正向净增益来自答案未变化状态。

条件	变化状态J/22	未变化状态J/188	变化对P/11
Qwen BM25	7	41	2
Qwen 恢复	5	85	1
Phi BM25	3	26	0
Phi 恢复	3	78	0

表注：11个变化问题对涉及十个发行人，94个未变化问题对涉及29个发行人，发行人在两个子集中有重叠；同题两状态保持成组。

Qwen增加42个正确状态，可分为未变化状态+44和变化状态−2；Phi增加的52个正确状态全部来自未变化状态。恢复方案在Qwen和Phi上分别产生9/94、20/94个未变化问题对的错误变化。在答案未变化的问题对

中，两版输出都合法的分别为57和62个，其中单位可比较的为56和62个，对应可判定错误变化率9/56、20/62。原版参考沿用为0/11、1/11。这些计数描述了同一成对任务中的不同失败方向。

回顾性的发行人配对分析中，变化状态相对于未变化状态的恢复增益差为Qwen -32.50、Phi -27.66个百分点。完整逐项区间见补充材料S10.2，保留计算覆盖全部22个变化状态。

六个自主条件在单状态与成对评分下保持相同严格排序。成对评价的价值体现为错误结构，而不是排名反转：它显示原版单侧成功、修订版单侧成功及两版都错。例如，通过协议门控后，Qwen BM25得到55个数值正确、51个数值加单位正确、48个联合正确状态，但只有13个双状态正确问题对；三个单位也正确的回答指向了其他accession。

协议合法性区分可读数值匹配与进入主要计分的数值匹配；引用与accession冲突和后续accession失配分别记在不同评分层。保留JSON字段中，Qwen/Phi BM25有64/210、49/210个可读数值匹配，主要计分则为55/210、32/210；恢复方案的辅助数值计数为95/210、93/210，对应主要计分94/210、82/210。表S16依据第5.1节的合法性规则分开列出各层结果。补充材料表S7和S7分别呈现已解析字段的数值诊断，以及七类保留的协议或前置失败状态。

表S16。 评分顺序分离协议、数值、单位与来源结果。

首个失败位置	Qwen恢复	Phi恢复	六自主条件合计
协议或前置条件失败	75	43	623
合法但数值错误	41	85	315
数值正确、单位错误	4	1	18
数值单位正确、指定accession错误	0	0	10
联合正确	90	81	294

表注：各类别按评分顺序互斥。1,260条条件状态记录复用210个状态；623项首层失败中有132项引用与accession冲突，另有十项出现在后续accession评分层。

S13.7 证据访问区分评价条件

检索审计评价开发集上的已知目标覆盖；参考辅助对照评价给定公告或原文上下文后的回答表现。

保留的同表示检索审计让BM25与MPNet在全部适用开发候选上排序原始fact text（表S17）。144个状态中110个的精确标注支持可映射到索引，34个未匹配状态全部保留分母。该诊断使用早期事实文本，与后续cross-encoder段落表示分开。

表S17。 共享输入上的已知目标覆盖区分词法与稠密检索。

检索器	目标Hit@5 /144	目标Hit@50 /144	MRR
BM25	31	73	0.14981
MPNet稠密检索	17	44	0.07726

表注：保留全部144开发状态和相同事实文本池。历史稠密输入含215条在384 token处截断的事实。MRR使用完整路由候选池中首个匹配目标的排名，未命中状态记零。既有发行人bootstrap中，稠密减BM25的Hit@5、Hit@50区间分别为[-24.66, 4.55]、[-33.52, -5.07]个百分点，属于描述性的目标覆盖区间；截断因素未被单独隔离。

参考辅助访问分别改变了公告级和来源容器级表现。正确公告BM25将Qwen联合正确数由48提高到56，将Phi由29提高到46，六比较校正后的p分别为0.1709、0.0655。原生完整来源正确率为Qwen 74.29%，发行人聚类95%区间[60.53, 86.57]；Phi为54.29%，区间[42.08, 66.67]。评分配置敏感性及单独登记的历史比较见补充材料S5.3。

完整来源条件下，在全部210状态中，Qwen有188条、Phi有154条协议合法回答，其中仍有32条、40条未满足原生数值和单位要求。该条件因此提供了一组在参考辅助定位之后仍然存在的错误，便于进一步检查。

开发集呈现不同模式：完整来源Qwen/Phi为67/144、35/144，低于恢复方案78/144、71/144。限制到134个共同覆盖状态后，结果仍为67对74、35对67。各划分十个状态超出五容器预算；开发集含38个段落与表格混合状态，测试为12个。这些差异提示需要将证据组成和阅读行为一同考察。容器完整性与因果解释的范围见第6.1节。

划分差异也出现在合法输出中：完整来源Qwen在开发与普通测试上分别有54、30项数值失配，Phi为60、38项。补充材料表S10保留完整互斥失败分解。这些分布为来源和问题层面的检查提供依据，尚未识别差异的原因。

S13.8 开发演示区分总体收益与变化状态收益

开发集来源绑定对照呈现出更高的总体联合正确数和更低的变化状态正确数。在144个Qwen开发状态上，规则与排序得到95个联合正确，单一accession绑定得到102个；十个变化状态的正确数由4降至2。对应控制中，LLM解析器分别增加-1和零个联合正确。补充材料S1.1保留表S1、全部七条件及来源层面的转换。

固定单轮LoRA适配[25]使用245个有支持训练状态和36个内部loss留出状态。种子42/43/44上，Qwen联合正确为111/112/112，Phi为106/108/106，对照分别为同一144开发状态上的102和90。Qwen的102个联合正确来自上述规则、排序与绑定条件。补充材料S1.2给出全部双态结果、样本标准差、复制对照及训练支持排除记录；开发范围见第6.1节。

S13.9 成对案例连接预测与原文单元格

可追溯案例展示同一问题对中的答案错误与来源错误。

图3采用证据恢复条件下的Q0691：Qwen返回两版参考值，Phi引用修订accession却继续给出原版数值。Q0296中，Turtle Beach两版封面均报告USD 197,795,766，Qwen BM25得到该数字，却在修订状态引用原始accession。案例保留官方URL、截止时间、来源哈希、上下文及预测。来源文件字节哈希与表格定位已核验；图为原文转录而非SEC网页截图。案例在已观察结果类别内按固定ID哈希选取（补充材料S5.3）。

S13.10 输出约束区分响应合法性与联合正确性

在开发集上，数值约束使适配Qwen的合法回答由130增至144，联合正确增加二；适配Phi的合法回答由140增至144，联合正确增加一。

六臂开发控制交叉未适配与seed42适配权重，以及自由、JSON外壳和数值字符串约束解码（表S3）。各家族六条件使用相同运行环境、提示词、证据和预算，参考留在线下。这批同时代对照与补充材料表S2的早期适配运行环境分开记录。

表注：J使用144状态，P使用72问题对，变化J使用十状态。全部对照在同一环境新生成，与表S2的历史运行环境分开；软件与成本见补充材料S5.4。

四项数值约束对自由解码的发行人聚类Holm p均为1.00，区间均包含零；四行的变化状态正确数均未增加。解码设计与成本见补充材料S3，等效及因果解释边界集中于第6.1节。

S14 方法与解释的详细记录

本节保留精简主文背后的完整表述。表号和图号指向保持不变的主文资产；这些记录不增加实验或主张。

S14.1 复用接口

复用接口将使用者自己的检索器和阅读模型接入状态评分与成对评分。使用者通过Python 3.10+加载器读取冻结快照并校验哈希。来源客户端按官方URL/哈希记录恢复原文文件。使用者构建适用证据，保存精确消息及原始输出，再在离线阶段对照参考评分。

表3。 复用接口分开处理模型输入与离线评价。

表注：新组件工具封存新请求。精确历史输入重建另需固定的提取与检索资产；补充材料S6说明两种入口及接口边界。

成对诊断按resource-native-v1单位配置报告答案变化与稳定性。未知单位对变化或稳定性保持不可比较；参考答案未变化的问题对的错误变化率分别报告完整问题对分母与可比较问题对分母。历史评分器和原始输出保持不变，保留输出一致性及逐条诊断差异见补充材料S7。

核心包为主文3.5说明的v1.0.0资源包，已明确限于自有内容的MIT/CC BY 4.0授权及具名维护人。受保护gate数据、私有人审工作簿、模型二进制和缓存均不纳入。源数据快照保留历史状态字段，当前包的发布授权及许可声明单独记录。

拟定的维护方案采用不可变修正记录，保留旧答案、accession、哈希、定位及受影响评价；语义修正需要人工裁决。

S14.2 回答方法

自主回答按公告路由、证据选择和阅读生成依次执行，两个状态共用冻结的方法与配置，分别使用各自截止时间内的证据。图1将该流程与离线评价分开。

自主输入与公告范围

任务要求系统在查询截止时间内，为所询问的财务事实选择最新适用公告。公共指令要求：“在指定接受时间截止条件下，为该财务事实选择最新适用公告；不提供目标accession。”其固定英文原句为“Select the latest applicable filing for this financial fact under the stated acceptance-clock cutoff; the target accession is not supplied.” 系统按固定JSON协议返回有限数值、规范单位、支持accession及引用，或选择弃答。

自主检索使用公共问题、发行人元数据、截止时间和适用语料。公共请求包含question、cutoff、clock_protocol和instruction；发行人关系在请求之外用于检索路由，检索到的证据另行提供给阅读模型。两状态的截止时间和适用证据不同，公开输入不含采集日期。参考记录以及gold定位、目标身份限于离线评分和明确隔离的诊断。公告证据包含公开可见的数值与accession，但自主输入不将某个accession标记为离线目标。

每对问题固定两个可用状态：c0取原版目标公告的SEC Accepted时间，c1取修订版目标公告的Accepted时间。936个公共状态均与相应时间戳一致，每对均满足c0 < c1。图1中，C(c)表示路由发行人内Accepted时间不晚于c的候选公告；结构化事实另在排序前按题干明确的annual/quarterly要求路由10-K/10-Q表单。公告报告期元数据另行记录，不在文档路由中按目标报告期作硬过滤。该构造评价指定公告状态下的回答，而非发现未知修订发生时间。SEC受理时间是声明的可用性代理：部分提交会在下一工作日传播[22]，时钟边界见第6.1节。

证据检索与恢复

证据访问条件区分自主选择与参考辅助选择。自主条件包括截止时间过滤BM25、稠密检索加重排，以及在开发集选定后冻结的证据恢复基线。证据恢复从公开表单路由后的最新可见公告中提取结构化事实，按题干解析出的期间、单位及明确指定的主体范围过滤。它去掉词法概念硬过滤，保留稠密检索与重排；没有合格事实时回退到截止时间过滤BM25选出的段落，分支选择只使用公共证据可用性。稠密检索器为sentence-transformers/all-mpnet-base-v2，重排器为cross-encoder/ms-marco-MiniLM-L-6-v2，保留固定快照、精确输入与失败沿革。

证据恢复先取得结构化事实候选，再按公开问题中的期间、单位和明确范围筛选及排序，取前列事实构成证据卡片。卡片保留数值、单位、期间和来源定位字段；有合格事实时使用卡片，无合格事实时回退到截止时间内的BM25原文段落。该分支由证据是否存在决定，回答正确与否不参与选择。

阅读模型与回答记录

阅读模型接收公共请求及所选证据，以固定JSON协议生成回答或弃答。每个状态单独生成；原版预测不作为修订版回答的输入。系统保留实际消息、原始生成文本、模型版本及输入哈希，随后由离线评分器检查数值、单位、来源和成对行为。参考辅助条件另列于实验部分，解码设置与证据预算在同一模型家族内固定。

S14.3 评价细节

实验利用成对资源考察回答收益来自哪些样本，以及证据访问改变后错误如何变化。自主结果、参考辅助条件与重复开发演示分别保留其评价身份。

实验条件与评价

Qwen2.5-7B-Instruct与Phi-3.5-mini-instruct使用相同证据和语义指令，采用各自原生聊天模板、BF16贪心解码、最多五条证据、8,192总token预算及512生成token预留[23, 24]。主比较采用已暴露普通测试上的冻结协议，其中Qwen复用保留输出。210个状态构成105个问题对，全部计划失败保留分母。候选池、缓存与成本详见补充材料S13。

自主条件使用截止时间过滤BM25、稠密检索重排或冻结的证据恢复方案（第4节）。参考辅助条件分别提供正确accession后由BM25搜索公告内证据，或提供参考定位的完整表格/段落容器。后者保留表头及上下文，不复制答案字段。五容器预算覆盖200/210个测试状态、134/144个开发状态，各余十个状态保留为失败。这些是证据访问条件，不构成检索与阅读损失的可加和因果分解。

评分区分协议合规与指定状态要求。V检查输出合法性以及引用与所提供证据的accession一致性；N、U分别检查有限十进制数值和规范单位是否匹配参考；A检查返回accession是否等于状态指定accession。主要数值和单位指标为VN、VNU，联合正确为$J = V \times N \times U \times A$，因此VN是经过协议门控的数值指标。例如Q0296中，回答可以给出两版共有的正确数值，却因在修订状态引用原版而不满足A；若引用本身与其声明的accession冲突，则更早不满足V。这两种失败都不意味着原版文件中的数值为假。

双状态正确在问题对上平均$P = J(\text{原版}) \times J(\text{修订版})$，并区分两版皆对、仅原版对、仅修订版对及两版皆错。参考数值与单位定义变化子集。错误变化要求未变化题对的两端预测合法且单位可比；原值沿用要求合法、单位可识别的修订预测等于原版参考、同时不同于新版参考。完整与可判定分母均保留。resource-native-v1支持USD、shares、CAD、USD/share及pure；历史配置及已解析字段诊断见补充材料S5/S7/S13。

发行人层面的配对分析保留两状态及同发行人内的相关性。登记比较采用发行人重采样及比较家族内的Holm校正；种子标准差表示固定问题上的训练波动。图2的增益异质性分析使用20,000次共同发行人重采样及逐项百分位区间，计算方案在既有结果方向已知后冻结。完整随机种子、比较家族与推断边界见补充材料S10.2/S13。

总体收益与成对错误

证据恢复提高了两个阅读模型的联合正确和双状态正确（表4），但答案变化子集呈现不同模式。

表4。 不同证据条件下的回答组成与双状态正确性。

表注：V、VN、VNU及J使用210个计划状态，P使用105个问题对。V包含引用一致性。R表示参考辅助访问，在各阅读模型内单独分组。各行固定采用resource-native-v1；统一复评使历史Qwen完整来源J由154变为156、P由74变为75，自主成绩不变。

Qwen恢复相对BM25增加42个正确状态，其中未变化状态+44、变化状态-2；Phi增加52个未变化正确状态，变化状态净增为零。在22个变化状态上，Qwen由7变为5，Phi保持为3。图2比较各子集内部的增益率，而不是不等大的子集总量。回顾性变化减未变化增益差分别为-32.50和-27.66个百分点；区间描述当前样本，不构成新的独立确认（补充材料S10.2）。

配对揭示总体提升之外的错误。恢复方案在Qwen、Phi上得到37/105、28/105个完整正确题对，同时在未变化题对上产生9/94、20/94个错误变化；限于合法且单位可比的题对时为9/56、20/62，原版参考沿用为0/11、1/11。六个自主条件在单状态和成对评分下严格排序相同。新增信息是单侧与共同失败的分布，而不是排名反转（补充材料表S14及图S1）。

失败分区也取决于评分顺序。六条件合计有132项引用与accession冲突进入623项协议/前置失败，另有十项在数值与单位匹配后才进入指定accession失败。1,260条条件状态记录复用210个状态。补充材料表S16保留完整分区及已解析字段诊断，避免将后置十项误读为全部来源错误。

正确公告与原文上下文访问

普通测试上，参考辅助访问提高了双状态成功：Qwen的P从BM25下13增加到正确公告下22、完整来源容器下75；Phi从5增加到18和52（表4）。完整来源条件下，在全部210个状态中，188条合法Qwen输出仍有32条、154条合法Phi输出仍有40条不满足原生数值/单位要求。这些残余错误可继续回到来源检查。

开发集呈现不同模式。完整来源Qwen/Phi为67/144、35/144，恢复方案为78/144、71/144；限制到134个共同覆盖状态仍为67对74、35对67。开发集有38个段落与表格混合状态，测试有12个。来源组成、长度与阅读行为共同变化，因此比较指出了一个证据接口问题，而没有识别其原因；完整容器也不保证语义充分。详细错误计数及已知目标检索覆盖见补充材料S13，目标覆盖使用标注定位而非池化相关性判断。

开发集适配与输出控制

开发演示考察改变证据处理或输出行为能否改善成对任务。规则式单accession绑定使Qwen联合正确由95提高到102/144，变化状态却由4降到2/10；对应LLM解析器增量为-1和零。固定单轮LoRA适配使用245个有支持训练状态和36个内部loss留出状态[25]。Qwen三个种子在144个开发状态上得到111/112/112，Phi为106/108/106，对照为102和90。完整结果与选择范围保留在补充材料S1。

同时代自由、JSON外壳与数值字符串约束对照区分输出合法性和联合正确性。数值约束使适配Qwen合法输出由130增至144，联合正确由111增至113；Phi合法输出由140增至144，联合正确由109增至110。四项模型/权重对照的变化状态正确数均未改变，四项Holm校正p均为1.00、区间包含零。这些重复开发控制既未建立等效，也未建立普遍提升，其运行环境与早期适配分开记录（补充材料S3）。

来源关联案例

来源关联案例使数值错误与指定来源错误的区别可以直接检查。

证据恢复下的Q0691（图3）中，Qwen返回两版参考值，Phi引用修订accession却继续给出原版数值。Q0296两版封面均为USD 197,795,766，Qwen BM25却在修订状态引用原版accession。案例在已观察结果类别内按固定ID哈希选择，官方URL、截止时间、哈希、表格定位和预测均保留；图为已核验来源单元格的转录，不是SEC截图（补充材料S5.3）。

S14.4 结论与范围

FilingRevisionQA以可追溯问题对连接原版与修订版财务公告，并提供数值、单位、指定来源和双状态正确性的可执行评价。在已评价阅读模型上，证据恢复相对截止时间过滤BM25的正向净增益来自答案未变化状态，而22个变化测试状态的联合正确数下降或持平。研究者可以使用成对目标和受控证据访问，比较检索与阅读组件，并回到原始公告追溯失败。

适用范围与局限

本文证据支持在以下范围内复用成对资源、诊断已评价系统。既有时序、可追溯来源、检索与适配研究提供基础，本文贡献为成对资源、可执行评价和观察到的失败结构。

总体与变化覆盖。 资源是选定的可追溯SEC问题对，而非全部披露的代表性样本。变化分析使用五个开发问题对和11个测试问题对；选择及来源支持要求、稀少变化和未决事件类别限制总体估计。

审核沿革。 审核说明由记录和作者确认支持。投影题干审核已有保留的批次作者确认，证据粒度见补充材料S5.2。AI筛选、语义解释和来源检查与人工判断分别记录。

评价历史。 开发集多次使用，后续普通测试比较为补充分析。冻结协议保留实验身份，多重比较校正适用于各自声明的比较家族；历史选择依赖仍然存在。内部留出已被检查，其中的可支持子集用于最终教师强制损失评价，因此仍属于诊断分区。训练随机种子反映固定问题上的训练波动；两个阅读模型家族的结果仍不足以确定其在更广泛模型中的适用性。

时间适用性。 证据是否符合截止时间，以Accepted时间为判定依据。零时钟违规表明系统符合既定代理时钟和冻结语料的要求；所有状态的精确历史公开时间仍未逐一独立确认。

来源核验与证据条件。 结构检查验证解析及定位。完整容器仍可能缺少充分语义上下文，其成绩描述所供证据条件，而非普遍性能上限；来源组成、长度、问题和阅读行为共同变化，因此不能将条件间的成绩差视为各环节可独立相加的因果影响。

适配与干预。 适配结论以来源支持规则筛选后的训练子集和选定证据接口为条件。复制控制、不完整引用支持、单一编号置换、耦合的遮蔽变化和特定解码约束限制推理及因果解释。预训练重叠仍可能存在，模型家族的分词器与参数规模不同，适配运行还使用了不同硬件。

负责任使用。 资源用于研究。修订状态本身不说明欺诈、不当行为、审计失败或投资风险。

参考文献

[1] Chen, Zhiyu; Chen, Wenhu; Smiley, Charese; et al. FinQA: A Dataset of Numerical Reasoning over Financial Data. 2021. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 3697-3711. https://aclanthology.org/2021.emnlp-main.300/.

[7] AhaSignals. AhaSignals Financial AI Point-in-Time Integrity Benchmark. 2026. AhaSignals. Version 1.1.0. https://doi.org/10.5281/zenodo.22289017.

[8] AhaSignals. Historical financial data revision sensitivity. 2026. Version 1.0.0. https://ahasignals.com/research/historical-data-revision-sensitivity/.

[9] AhaSignals. Historical financial differences: context and precision review. 2026. Version 1.0.0. https://ahasignals.com/research/historical-data-revision-sensitivity/#document-review.

[10] Liu, Zhiwei; He, Yueru; Ou, Qing; et al. AuditFraudBench: Benchmarking Audit Judgment in Detecting Fraudulent Misstatements. 2026. Version 1. https://arxiv.org/abs/2606.08345v1.

[11] Mansouri, Sasan; Saad, Daniel; Wahrenburg, Mark; et al. FinRank: An Evidence-Grounded Benchmark for Financial Question Answering and Retrieval over SEC Filings. 2026. Version 1. https://arxiv.org/abs/2608.07400v1.

[12] Cymbler, Rose; Guez, Daniel; Fabre, Laurent. Temporal Misgrounding in Legal RAG: A Versioned-Corpus Benchmark for French Tax Law. 2026. Version 1. https://arxiv.org/abs/2608.09393v1.

[13] Huwiler, Daniel; Stockinger, Kurt; Fürst, Jonathan. VersionRAG: Version-Aware Retrieval-Augmented Generation for Evolving Documents. 2025. Version 1. https://arxiv.org/abs/2510.08109v1.

[20] Xu, Chuhong; Su, Bo; Chen, Ziyao; et al. Same-Number Citation Swaps: Stress-Testing Jev as a Financial Evidence Judge. 2026. Version 2. https://arxiv.org/abs/2610.08675v2.

[22] U.S. Securities and Exchange Commission. Accessing EDGAR Data. 2021. https://www.sec.gov/search-filings/edgar-search-assistance/accessing-edgar-data.

[23] Qwen; Yang, An; Yang, Baosong; et al. Qwen2.5 Technical Report. 2024. Version 2. https://arxiv.org/abs/2412.15115v2.

[24] Microsoft. Phi-3.5-mini-instruct Model Card. 2024. https://huggingface.co/microsoft/Phi-3.5-mini-instruct.

[25] Hu, Edward J.; Shen, Yelong; Wallis, Phillip; et al. LoRA: Low-Rank Adaptation of Large Language Models. 2021. Version 2. https://arxiv.org/abs/2106.09685v2.

[26] Hui, Binyuan; Yang, Jian; Cui, Zeyu; et al. Qwen2.5-Coder Technical Report. 2024. Version 3. https://arxiv.org/abs/2409.12186v3.